Guía completa de gráficos para el análisis exploratorio de datos (EDA)

Material didáctico para bootcamp básico de IA

Idea clave: en EDA no se grafican datos "por decorar". Cada gráfico responde una pregunta distinta: distribución, comparación, relación, evolución temporal, presencia de nulos o señales que pueden afectar el modelado.

Esta guía amplía la guía breve que compartiste y organiza los gráficos más importantes del EDA de forma más profunda y pedagógica. El enfoque es práctico: qué muestra cada gráfico, cómo se lee, qué patrones permite descubrir y por qué resulta útil antes de entrenar un modelo de machine learning.

En términos sencillos, los gráficos cumplen cuatro funciones grandes dentro del EDA: entender la forma de una variable, comparar grupos, estudiar relaciones entre variables y detectar problemas de calidad de datos. En las referencias usadas para esta guía, Penn State describe que las tablas de frecuencia, los gráficos de barras y los gráficos circulares sirven para variables categóricas; mientras que histogramas, boxplots y scatterplots ayudan a estudiar variables cuantitativas y relaciones entre ellas. [R1][R2][R3]

1. ¿Cómo elegir el gráfico correcto?

Antes de escoger el gráfico, lo primero es identificar el tipo de variable y la pregunta analítica.

Tipo de pregunta	Tipo de variable	Gráfico recomendado	Qué ayuda a detectar
¿Cuántos casos hay por categoría?	Categórica	Barras	Desbalance de clases, categorías dominantes
¿Cómo se distribuye una variable numérica?	Numérica	Histograma	Sesgo, concentración, huecos, colas
¿Hay valores atípicos o diferencias entre grupos?	Numérica + categórica	Boxplot	Outliers, dispersión, mediana, IQR
¿Se relacionan dos variables numéricas?	Dos numéricas	Scatter plot	Tendencias, nubes, outliers, no linealidad
¿Qué variables se mueven juntas?	Varias numéricas	Matriz de correlación / heatmap	Redundancia, multicolinealidad
¿Dónde faltan datos?	Cualquier tipo	Diagrama de nulos	Patrones de ausencia, columnas críticas
¿Cómo cambia una medida en el tiempo?	Temporal + numérica	Gráfico de línea	Tendencias, cambios bruscos, estacionalidad
¿Cómo se reparte el total?	Categórica	Circular (con cautela)	Participación porcentual

2. Gráfico de barras

¿Para qué sirve?

Sirve para mostrar el número de casos o el porcentaje de cada categoría. Penn State define el gráfico de barras como un gráfico para una variable nominal u ordinal, donde el tamaño de cada barra representa el número de casos de esa categoría y las barras aparecen separadas porque se trata de categorías, no de una escala continua. [R2][R4]

¿Cómo se lee?

Se compara la altura o la longitud de las barras. Una barra más larga indica mayor frecuencia o mayor proporción. Si el objetivo es comparar categorías, conviene ordenar las barras de mayor a menor o respetar el orden natural de la variable cuando sí existe (por ejemplo: bajo, medio, alto).

¿Qué patrones permite ver?

Permite detectar categorías dominantes, categorías raras, clases poco representadas y desbalances severos. En dos variables categóricas, una versión agrupada o apilada permite comparar combinaciones entre grupos. Penn State explica que un clustered bar chart representa una combinación por barra y ayuda a ver qué grupos son los más grandes o los más pequeños. [R5]

¿Para qué sirve en machine learning?

Es muy útil para revisar la variable objetivo en problemas de clasificación. Si una clase tiene muchísimos más registros que otra, el modelo puede aprender con sesgo hacia la clase mayoritaria. También ayuda a detectar categorías con muy pocos casos, las cuales pueden requerir agrupación o tratamiento especial.

Errores comunes

Usarlo con demasiadas categorías, no ordenar cuando el orden mejora la lectura, mezclar frecuencias con porcentajes sin aclararlo, o emplearlo para datos continuos que deberían ir en histograma.

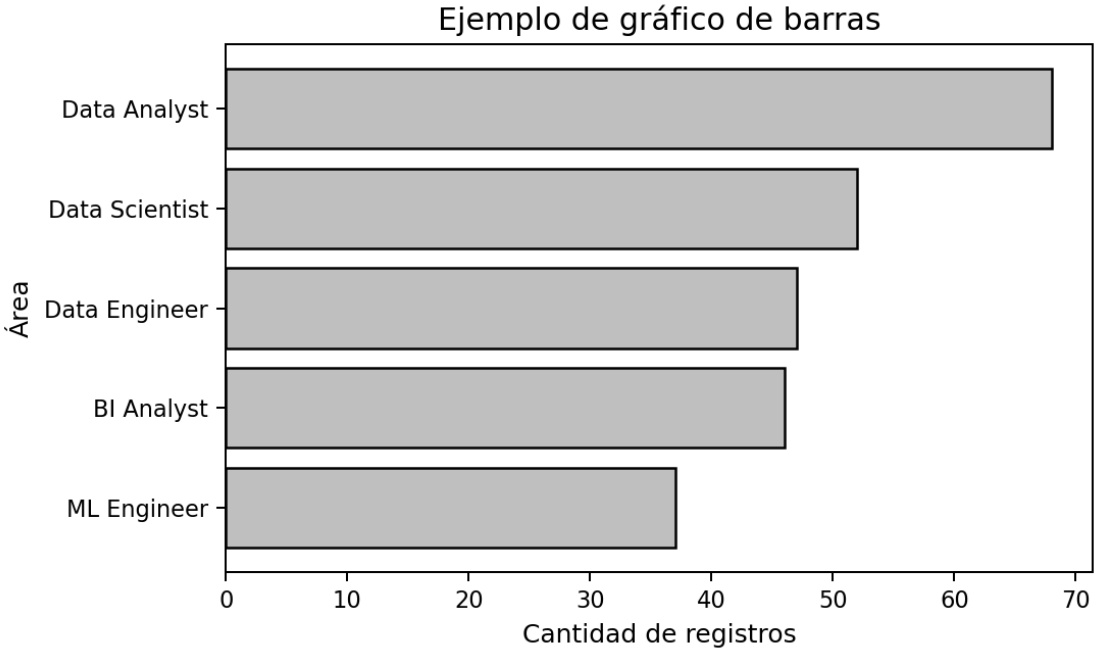

Interpretación del ejemplo: el área con más registros destaca con una barra claramente más larga. En un proyecto real, esto alertaría sobre posibles categorías sobrerrepresentadas.

3. Histograma

¿Para qué sirve?

Es el gráfico clásico para estudiar la distribución de una variable numérica. Penn State señala que el histograma es una de las herramientas gráficas más comunes para representar datos continuos: en el eje horizontal se ubican intervalos de valores y en el vertical la frecuencia o frecuencia relativa. También aclara que el ancho de clase influye en la forma observada. [R6]

¿Cómo se lee?

No se leen barras como categorías independientes, sino como rangos. Lo importante es mirar dónde se concentra la mayor parte de los datos, si la distribución es simétrica o sesgada, si hay colas largas, huecos o varios picos.

¿Qué patrones permite ver?

Permite observar sesgo a la derecha o a la izquierda, multimodalidad, concentración en ciertos rangos y presencia de valores extremos. Un histograma también puede sugerir si una transformación como logaritmo podría ayudar cuando una variable está muy sesgada.

¿Para qué sirve en machine learning?

Ayuda a decidir si una variable requiere escalado, transformación o tratamiento de outliers. También es útil para revisar la distribución de residuos o errores; Penn State menciona histogramas y boxplots como parte de la verificación visual de supuestos en modelos. [R7]

Errores comunes

Escoger demasiados o muy pocos bins, concluir demasiado a partir de una muestra pequeña o comparar histogramas con escalas distintas sin advertirlo.

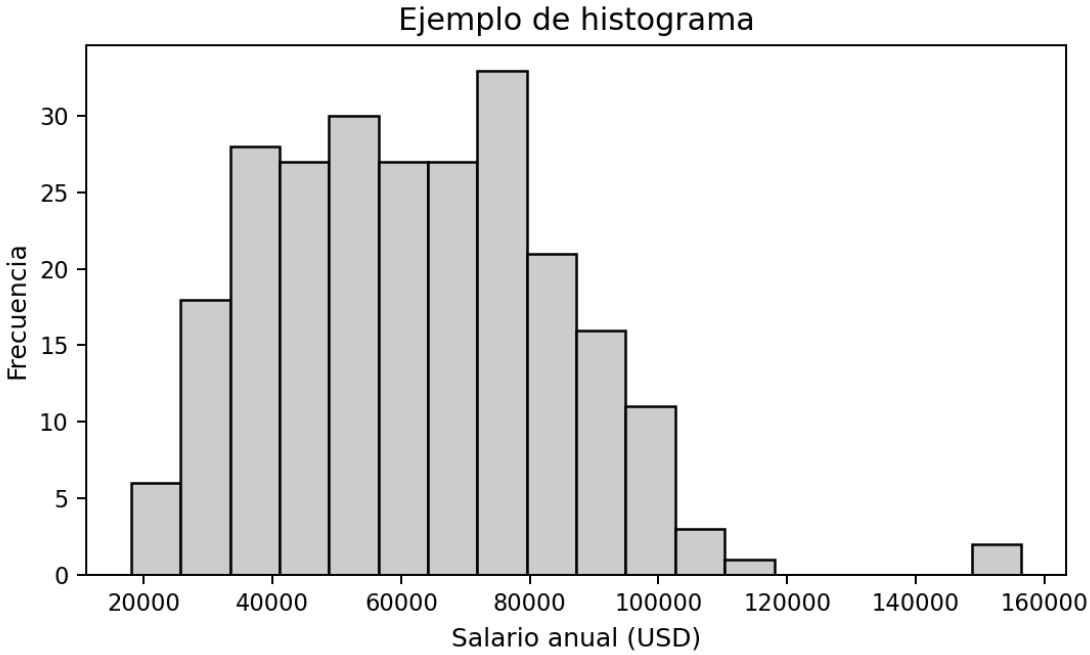

Interpretación del ejemplo: la mayor parte de salarios se concentra en un rango intermedio, pero hay una cola hacia valores altos. Eso sugiere asimetría positiva y presencia de algunos salarios excepcionalmente altos.

4. Diagrama de cajas (boxplot)

¿Para qué sirve?

Resume rápidamente mediana, dispersión y posibles outliers. Penn State indica que el método del IQR se usa para identificar valores atípicos y que los boxplots lado a lado facilitan comparar la mediana, el IQR y el rango entre grupos. [R1]

¿Cómo se lee?

La línea dentro de la caja es la mediana. La caja representa el 50 % central de los datos (Q1 a Q3). Los bigotes muestran la extensión de valores no atípicos según la regla elegida y los puntos aislados suelen indicar observaciones potencialmente atípicas.

¿Qué patrones permite ver?

Permite comparar grupos por centro y variabilidad. Si una caja es más alta, hay más dispersión. Si la mediana está descentrada o los bigotes son muy desiguales, puede existir sesgo. Si aparecen muchos puntos aislados, hay valores que conviene investigar.

¿Para qué sirve en machine learning?

Sirve para detectar registros extremos que podrían distorsionar medias, escaladores o modelos sensibles a valores atípicos. También ayuda a comparar la variable objetivo o alguna feature por segmento, por ejemplo salario por nivel o tiempo de respuesta por canal.

Errores comunes

Creer que todo punto atípico es un error, no revisar el contexto del negocio y olvidar que el boxplot resume la distribución pero no reemplaza ver la forma completa con un histograma.

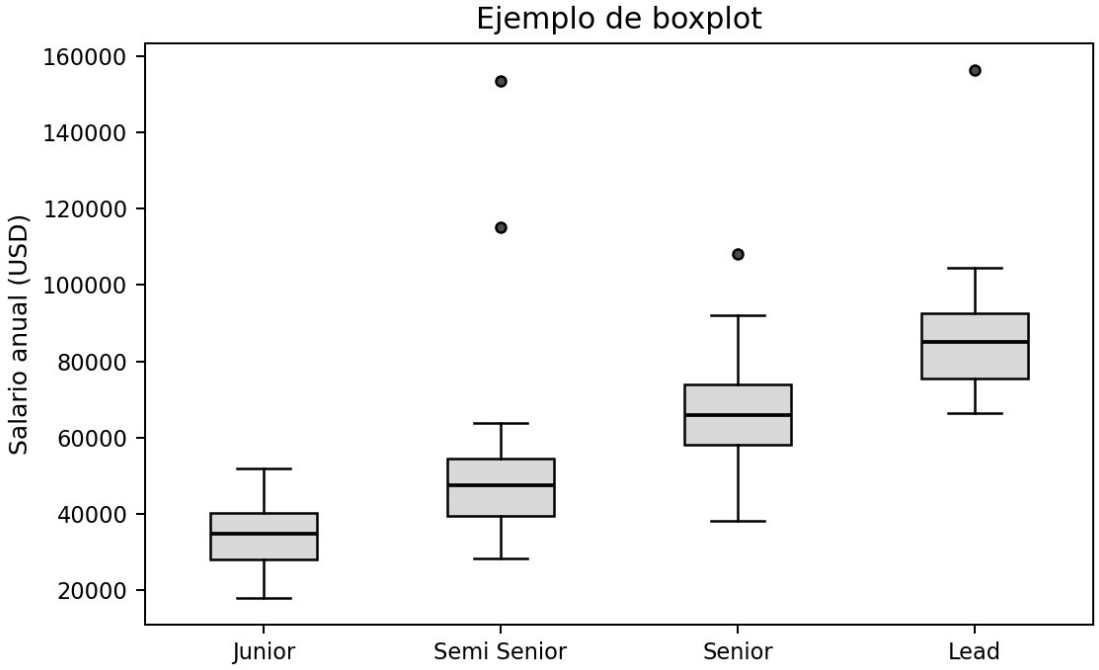

Interpretación del ejemplo: los grupos Senior y Lead muestran medianas más altas que Junior. Además, aparecen puntos muy altos fuera del patrón general, lo que sugiere outliers que convendría validar.

5. Gráfico de dispersión (scatter plot)

¿Para qué sirve?

Es el gráfico más importante para estudiar la relación entre dos variables numéricas. Penn State lo presenta como la herramienta para entender si existe asociación entre variables de medición y para observar lo que la nube de puntos “está contando”. [R3]

¿Cómo se lee?

Cada punto representa un caso. Se observa la dirección general de la nube (ascendente, descendente o sin patrón), la fuerza aparente de la asociación, la forma de la relación (lineal o no lineal) y la presencia de grupos o puntos alejados.

¿Qué patrones permite ver?

Puede mostrar correlación positiva, negativa o nula; relaciones curvas; clústeres; heterogeneidad entre segmentos; y observaciones extremas. También es útil para detectar si la relación cambia por grupos cuando se colorean o diferencian categorías.

¿Para qué sirve en machine learning?

Ayuda a anticipar si un modelo lineal puede capturar bien la relación o si conviene probar transformaciones o modelos no lineales. En diagnóstico de modelos, los scatterplots de residuos ayudan a revisar tendencias, variación no constante y posibles transformaciones necesarias. [R7]

Errores comunes

Interpretar correlación como causalidad, ignorar la influencia de outliers, no revisar sobreposición de puntos y olvidar que puede haber patrones ocultos por segmentos.

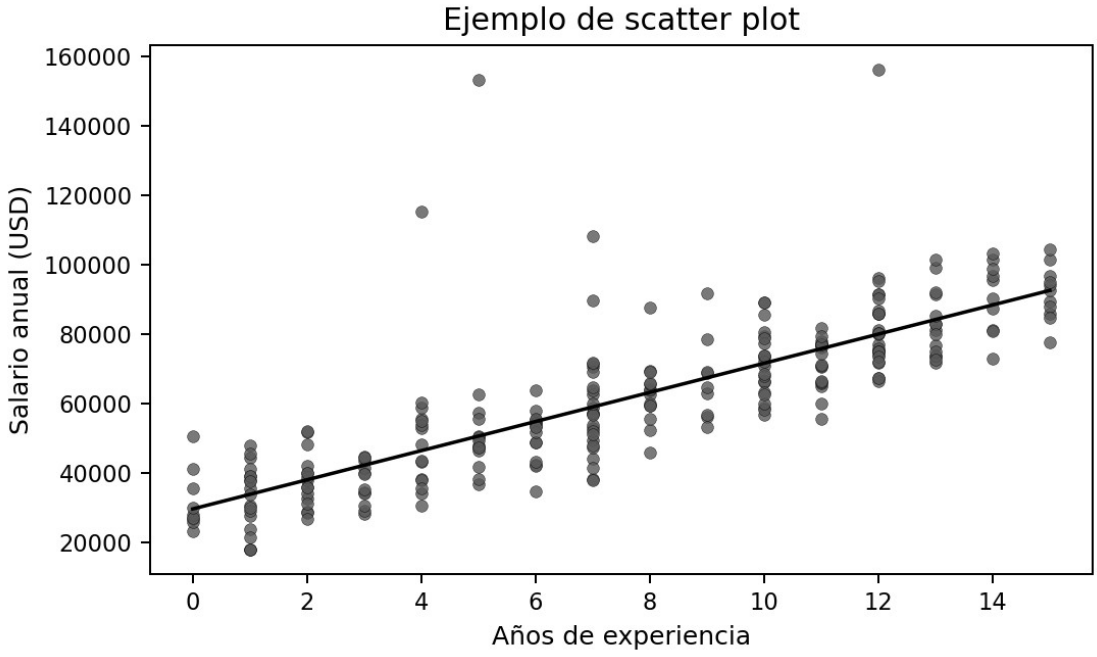

Interpretación del ejemplo: la tendencia general es ascendente, así que a mayor experiencia parece haber mayor salario. Sin embargo, no todos los puntos caen sobre una línea: hay dispersión y algunos casos excepcionalmente altos.

6. Matriz de correlación y heatmap

¿Para qué sirve?

Permite ver de manera compacta cómo se relacionan varias variables numéricas entre sí. Una matriz de correlación resume pares de variables y un heatmap los convierte en una imagen codificada por intensidad. Matplotlib describe el heatmap como una imagen coloreada útil para datos que dependen de dos variables, y Penn State lo presenta como una forma de visualizar bloques o patrones en una matriz. [R8][R9]

¿Cómo se lee?

Cada celda cruza dos variables. El valor cercano a 1 indica asociación lineal positiva fuerte; cercano a -1, asociación lineal negativa fuerte; y cercano a 0, asociación lineal débil o ausente. La diagonal principal vale 1 porque cada variable está perfectamente correlacionada consigo misma.

¿Qué patrones permite ver?

Detecta redundancia entre variables, grupos de variables que se mueven juntas y señales de multicolinealidad. También ayuda a elegir variables para una primera selección de features, aunque nunca debería ser el único criterio.

¿Para qué sirve en machine learning?

Es especialmente útil antes de modelos lineales, regresión logística o cualquier modelo donde la colinealidad pueda afectar estabilidad e interpretación. También ayuda a evitar incluir variables casi duplicadas. Aun así, recuerda que correlación alta no implica causalidad ni garantiza utilidad predictiva.

Errores comunes

Usarla con variables categóricas codificadas sin sentido, interpretar correlación lineal como relación total, o eliminar variables solo porque están correlacionadas sin revisar contexto.

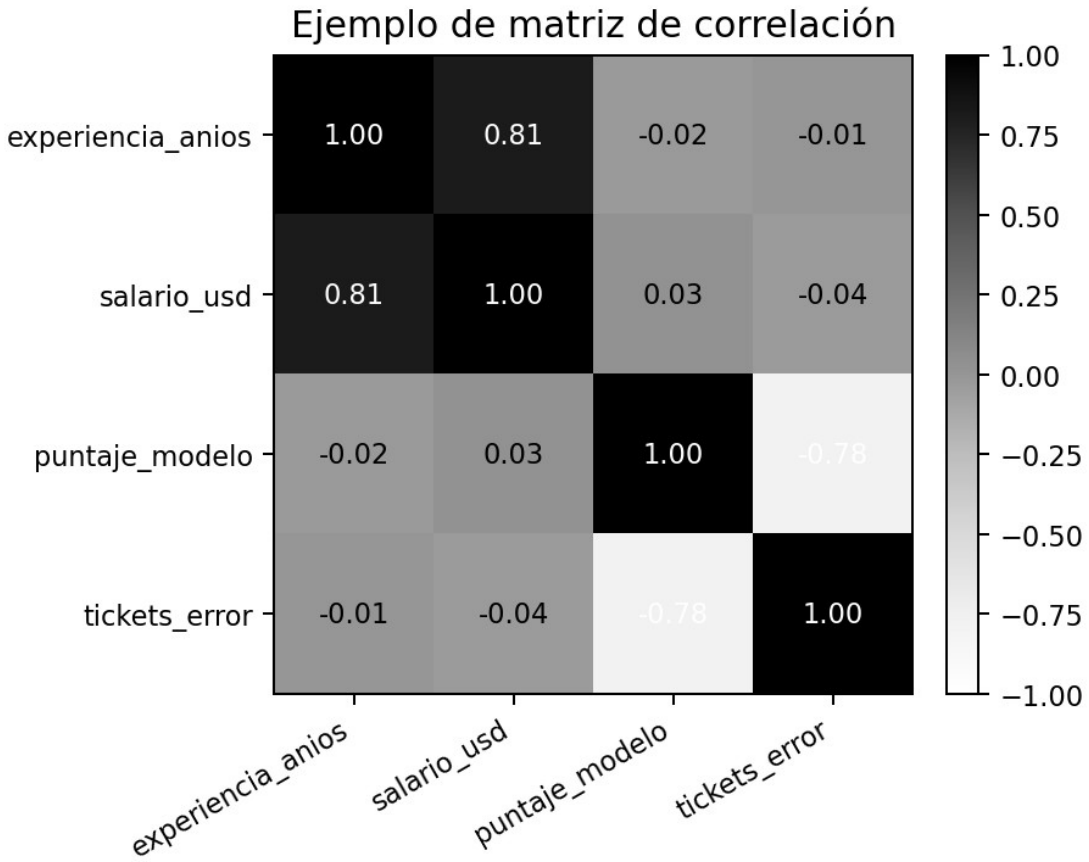

Interpretación del ejemplo: experiencia y salario muestran asociación positiva. Puntaje y tickets de error presentan asociación negativa, lo que sugiere que a mayor puntaje pueden aparecer menos errores.

7. Diagrama de nulos

¿Para qué sirve?

Sirve para ver dónde faltan datos y si las ausencias siguen algún patrón. Aunque muchas veces se enseña de forma separada, dentro del EDA es clave porque la calidad del análisis depende de la completitud y la distribución de los faltantes.

¿Cómo se lee?

Cada columna representa una variable y cada marca o franja oscura indica presencia o ausencia de datos según la convención usada. Lo importante no es solo contar nulos, sino identificar si se concentran en ciertas variables o si coinciden entre columnas.

¿Qué patrones permite ver?

Permite detectar columnas muy incompletas, bloques de registros afectados, faltantes simultáneos y posibles dependencias. Si los nulos se concentran en cierto segmento, eso puede ser una pista de sesgo en la captura o en el proceso de negocio.

¿Para qué sirve en machine learning?

Ayuda a decidir si conviene imputar, eliminar filas, eliminar columnas o crear indicadores de ausencia. También previene entrenar modelos con una base que parece grande, pero en realidad queda muy reducida al filtrar registros completos.

Errores comunes

Mirar solo el conteo total de nulos y no su patrón; imputar de forma automática sin entender por qué faltan; o borrar columnas importantes solo por comodidad.

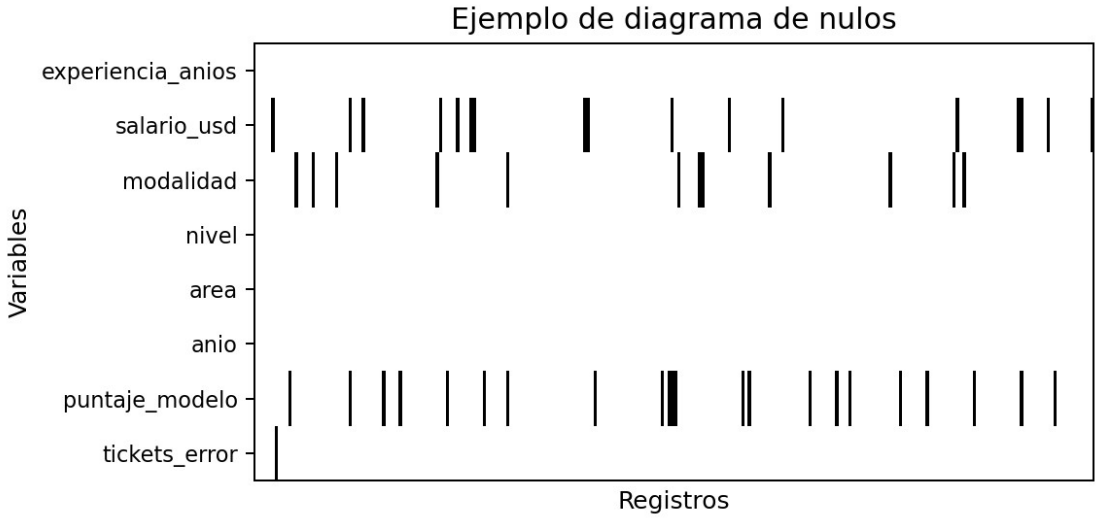

Interpretación del ejemplo: varias ausencias se concentran en salario y puntaje del modelo. Esto sugiere que no basta con contar nulos: hay que revisar si ciertos campos faltan juntos y si eso afecta el análisis.

8. Gráfico de línea

¿Para qué sirve?

Es el gráfico de referencia cuando una variable numérica se observa a lo largo del tiempo o de una secuencia ordenada. Su fuerza no está en comparar categorías sueltas, sino en mostrar continuidad y evolución.

¿Cómo se lee?

Se observa la trayectoria de la línea: sube, baja, se estabiliza, oscila o presenta saltos bruscos. También importa revisar la pendiente, los cambios de tendencia y la presencia de picos o caídas anómalas.

¿Qué patrones permite ver?

Permite identificar tendencia, estacionalidad, ciclos, cambios estructurales y momentos atípicos. En datos de negocio, es ideal para ventas mensuales, tráfico, incidentes, errores de un modelo o métricas de rendimiento a lo largo del tiempo.

¿Para qué sirve en machine learning?

Ayuda a validar si existe deriva temporal, si los datos deben dividirse respetando el tiempo y si las variables cambian de forma no estacionaria. También sirve para monitorear modelos desplegados: precisión, error, demanda o latencia en el tiempo.

Errores comunes

Usarlo para categorías sin orden temporal, unir puntos que no deberían estar conectados o no revisar si la escala del eje exagera cambios pequeños.

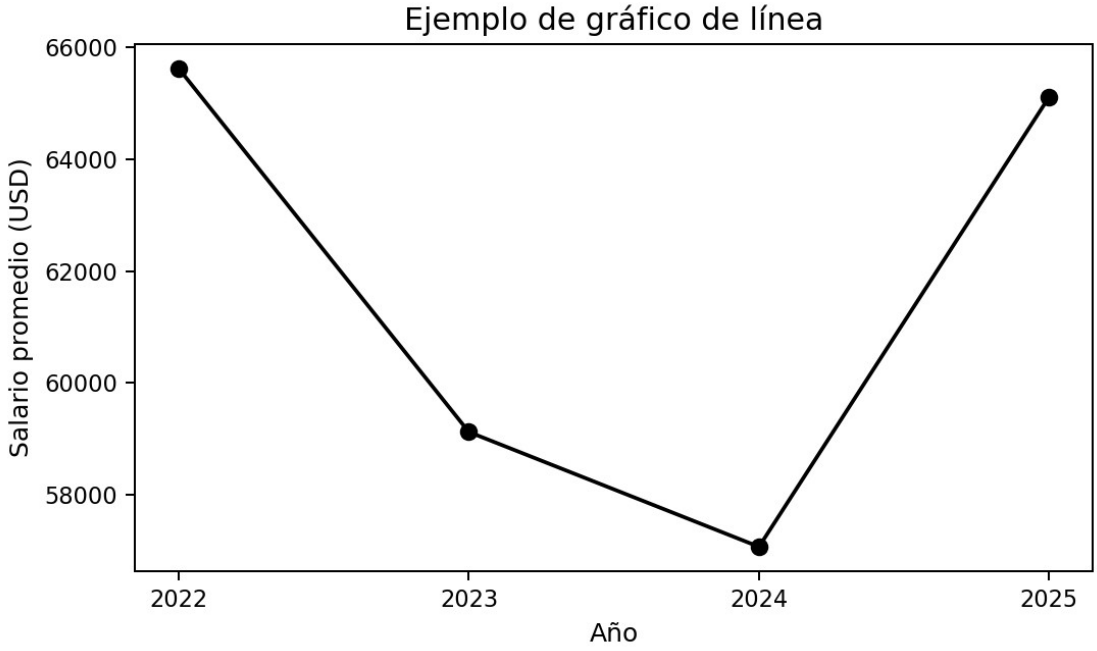

Interpretación del ejemplo: el salario promedio sube de un año a otro. En un problema real, esto podría relacionarse con inflación, cambios de mercado o transformaciones en el perfil de contratación.

9. Gráfico circular (uso complementario, no principal)

¿Para qué sirve?

Muestra la proporción de cada categoría respecto del total. Penn State lo define como un gráfico que divide un círculo en “rebanadas” que representan la proporción por categoría. [R4]

¿Cómo se lee?

Se comparan áreas o ángulos, no alturas. Por eso suele ser menos preciso que un gráfico de barras cuando necesitamos comparar categorías cercanas entre sí.

¿Qué patrones permite ver?

Permite comunicar participación porcentual cuando hay pocas categorías y la intención es muy descriptiva. Funciona mejor con 3 a 5 categorías; si hay muchas, la lectura se vuelve difícil.

¿Para qué sirve en machine learning?

Tiene valor más comunicativo que analítico. Puede servir para presentar la composición general de una variable categórica, pero para detectar desbalance, pequeñas diferencias o cambios entre grupos suele ser mejor el gráfico de barras. Penn State también advierte que los pie charts funcionan mejor cuando hay pocas categorías. [R2]

Errores comunes

Usarlo con demasiadas categorías, comparar tamaños muy parecidos o convertirlo en el gráfico principal cuando una barra comunicaría mejor.

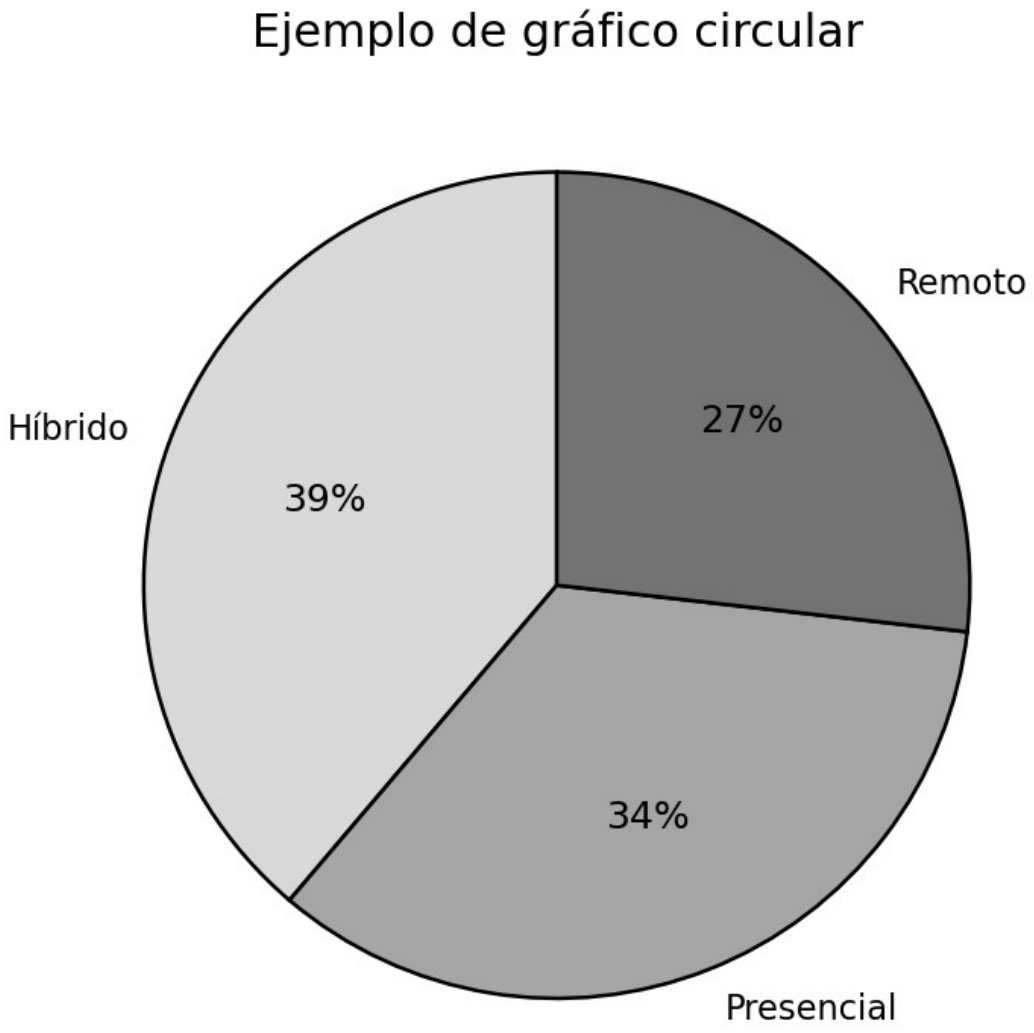

Interpretación del ejemplo: permite ver la proporción general entre remoto, híbrido y presencial, pero no es el mejor gráfico si queremos comparar diferencias pequeñas con precisión.

10. Recomendaciones pedagógicas para tus estudiantes

- No pedir gráficos “por cumplir”, sino asociar cada gráfico a una pregunta guía.
- Pedir siempre una mini interpretación: qué se observa, qué podría significar y qué habría que validar después.
- Combinar gráficos: histograma + boxplot para una variable numérica; barras + tabla de frecuencias para una variable categórica; scatter + correlación para dos numéricas.
- Insistir en que un gráfico no reemplaza el contexto del problema ni la limpieza previa.
- Conectar el EDA con el siguiente paso: selección de variables, tratamiento de nulos, manejo de outliers y preparación para modelado.

11. Cuadro de cierre: qué responde cada gráfico

Gráfico	Pregunta principal	Tipo de dato	Hallazgo típico	Decisión posible

Barras	¿Qué categorías dominan?	Categórico	Clases desbalanceadas	Agrupar categorías o re-muestrear
Histograma	¿Cómo se distribuye la variable?	Numérico	Sesgo y colas	Transformar o escalar
Boxplot	¿Hay outliers o diferencias entre grupos?	Numérico / numérico+categórico	Atípicos y dispersión	Validar extremos o segmentar
Scatter	¿Existe relación entre dos variables?	Dos numéricos	Asociación o curvatura	Elegir modelo o transformar
Correlación heatmap	¿Qué variables se parecen mucho?	Varias numéricas	Redundancia	Reducir variables
Nulos	¿Dónde falta información?	Mixto	Patrón de ausencia	Imputar o depurar
Línea	¿Cómo cambia algo en el tiempo?	Temporal	Tendencia y cambios bruscos	Partición temporal y monitoreo
Circular	¿Cómo se reparte el total?	Categórico	Participación porcentual	Comunicar composición

12. Cierre

Dentro del EDA, los gráficos no son un adorno visual: son una herramienta para pensar. Un buen análisis exploratorio usa gráficos para descubrir estructura, detectar problemas y tomar decisiones previas al modelado. En un bootcamp básico, la meta no es que el estudiante memorice nombres, sino que aprenda a elegir el gráfico correcto para la pregunta correcta.

Referencias

[R1] Penn State STAT 200, 'Describing Data, Part 2': boxplots, outliers, scatterplots, histograms con grupos y comparación entre distribuciones.

[R2] Penn State STAT 200, 'One Categorical Variable' y 'Visual Representations': tablas de frecuencia, gráficos de barras y gráficos circulares para variables categóricas.

[R3] Penn State STAT 100, 'Relationships Between Measurement Variables': uso de scatterplots para estudiar asociación entre variables numéricas.

[R4] Penn State STAT 200, 'One Categorical Variable': advertencia de que los gráficos circulares funcionan mejor cuando hay pocas categorías.

[R5] Penn State STAT 200, 'Two Categorical Variables': clustered bar chart para combinaciones de variables categóricas y elección del mejor visual según el objetivo.

[R6] Penn State STAT 508, 'Exploratory Data Analysis': histogramas para datos continuos y efecto del ancho de clase en la forma observada.

[R7] Penn State STAT 462, 'Assessing the Model Assumptions': scatterplots de residuos e histogramas/boxplots para revisar supuestos y posibles transformaciones.

[R8] Matplotlib documentation, 'Annotated heatmap': heatmap como imagen codificada por color para datos dependientes de dos variables.

[R9] Penn State STAT 555, 'Heatmaps': lectura de bloques y patrones en matrices visuales.