Normalidad en datos para análisis y machine learning

Guía práctica con histograma, QQ-plot, boxplot y prueba de Shapiro-Wilk

Idea clave: la normalidad describe si una variable numérica se distribuye de forma aproximadamente simétrica alrededor de su media, con mayor concentración en el centro y menor frecuencia hacia los extremos. No toda variable real debe ser normal, pero revisar esta forma ayuda a entender sesgo, colas, valores atípicos y posibles transformaciones.

1. ¿Qué significa normalidad?

Una variable con distribución normal tiene forma de campana: la mayoría de los datos se ubican cerca del centro y cada vez hay menos observaciones al alejarnos hacia la izquierda o la derecha.

En la práctica, revisar normalidad ayuda a describir mejor los datos, detectar comportamientos extraños y decidir si conviene transformar la variable, por ejemplo con logaritmos. También es útil en algunos métodos estadísticos que asumen normalidad o residuos aproximadamente normales.

En machine learning no siempre es obligatorio que la variable objetivo o los predictores sean normales. Sin embargo, analizar esta forma sigue siendo valioso porque permite entender la estructura de los datos antes de modelar.

2. ¿Qué se puede encontrar al revisar normalidad?

Patrón	Interpretación
Simetría	La distribución se parece en ambos lados del centro.
Sesgo o asimetría	Un lado concentra más masa o una cola es más larga que la otra.
Colas largas	Existen valores extremos o mucha dispersión hacia un lado.
Valores atípicos	Hay observaciones alejadas del resto.
Multimodalidad	Aparecen dos o más picos, señal de posibles subgrupos mezclados.
Concentración central	Los datos están muy apretados cerca del centro o muy dispersos.

3. Gráfico 1: Histograma con curva normal teórica

¿Para qué sirve? Permite comparar la forma real de la variable con una campana normal construida usando la media y la desviación estándar de los datos.

¿Cómo se lee? Si las barras del histograma siguen de manera aproximada la forma de la curva, existe cierta cercanía a la normalidad. Si la distribución se ve muy inclinada, con varias montañas o con colas largas, la normalidad es débil o no existe.

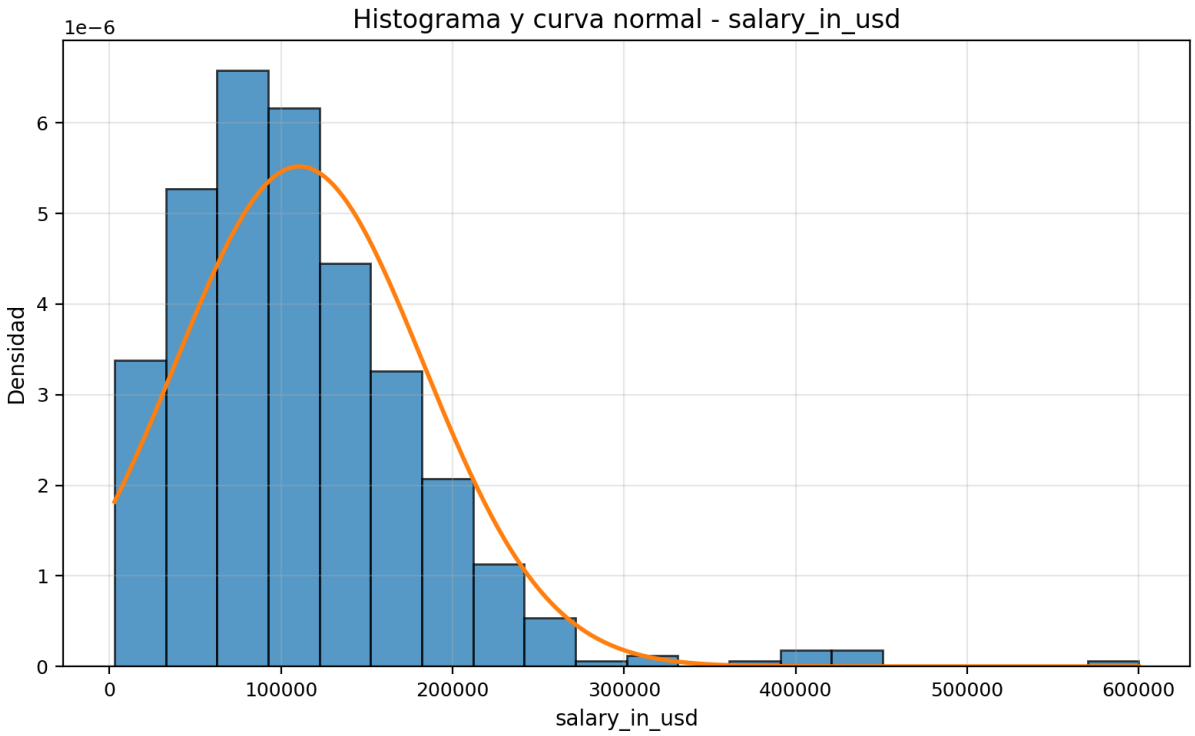

Figura 1. Histograma y curva normal de salary_in_usd

Si la cola derecha es más larga, hay sesgo positivo: existen salarios muy altos que arrastran la distribución hacia la derecha.

Si la cola izquierda es más larga, hay sesgo negativo: aparecen valores bajos alejados del resto.

Si un lado se ve más 'llenito' que el otro, la distribución no está balanceada alrededor del centro y por tanto no es simétrica.

4. Gráfico 2: QQ-plot

¿Para qué sirve? Compara los cuantiles observados de la variable con los cuantiles esperados de una distribución normal.

¿Cómo se lee? Si los puntos se alinean cerca de la recta, hay mayor parecido con una distribución normal. Cuando los puntos se curvan, se apartan mucho de la línea o los extremos se despegan, la normalidad se debilita.

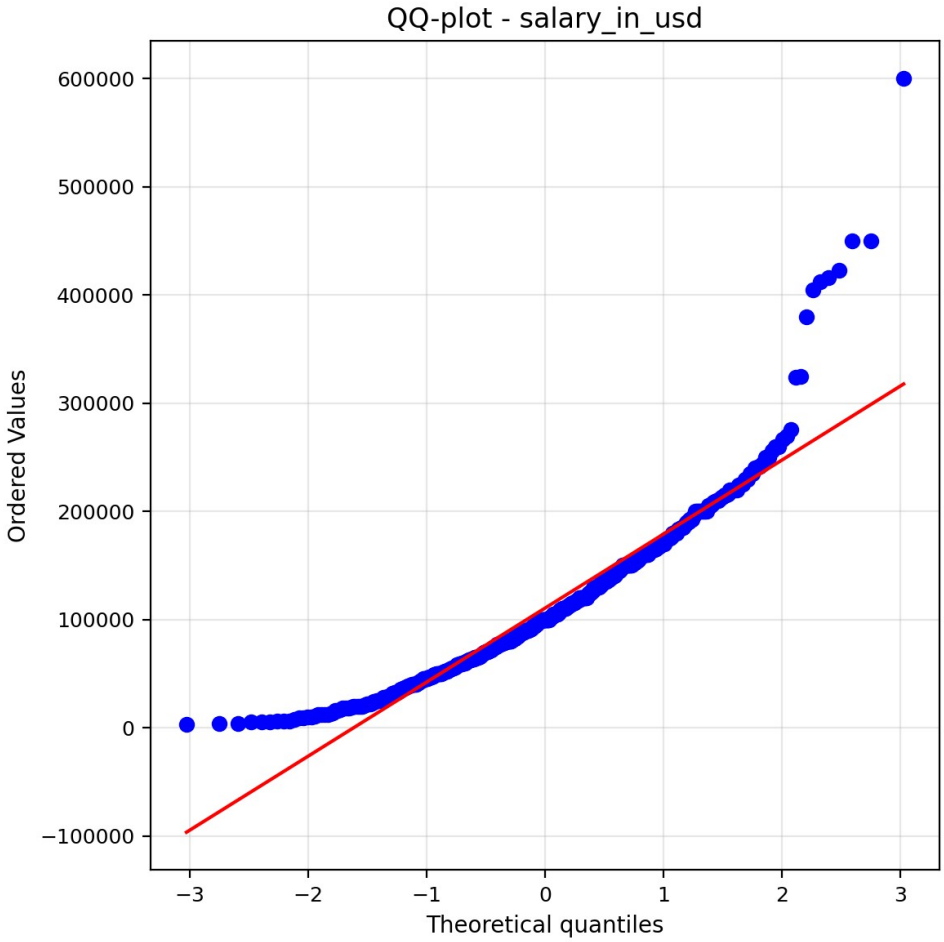

Figura 2. QQ-plot de salary_in_usd

Desviaciones en los extremos suelen indicar colas pesadas o muchos valores atípicos.

Una curvatura marcada suele sugerir sesgo.

Si el centro sigue la línea pero las puntas se abren, la parte central es relativamente estable pero las colas no son normales.

5. Gráfico 3: Boxplot

¿Para qué sirve? Resume la distribución mediante la mediana, los cuartiles y los posibles valores atípicos.

¿Cómo se lee? La caja muestra el 50% central de los datos; la línea interna es la mediana; los bigotes muestran la extensión normal de los datos; los puntos alejados representan posibles atípicos.

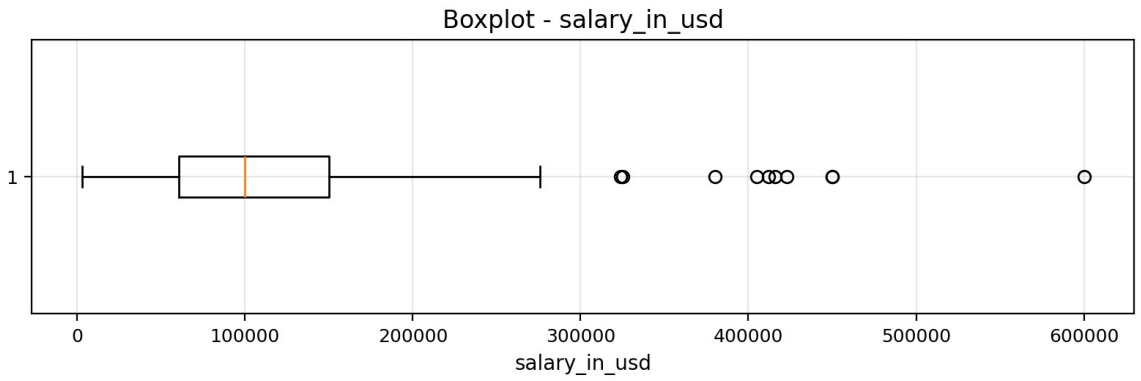

Figura 3. Boxplot de salary_in_usd

Si la mediana no queda centrada dentro de la caja, puede haber asimetría.

Si un bigote es mucho más largo que el otro, existe sesgo hacia ese lado.

Si aparecen muchos puntos fuera de los bigotes, hay valores atípicos que afectan la forma de la distribución.

6. Prueba de Shapiro-Wilk

¿Qué hace? Es una prueba estadística que contrasta si los datos provienen de una distribución normal.

Regla básica de interpretación: si el p-valor es mayor que 0.05, no hay evidencia fuerte para rechazar la normalidad. Si el p-valor es menor o igual a 0.05, la normalidad es poco probable.

Resultado obtenido	Lectura
Estadístico W = 0.8907	Mientras más se aleje de 1, menor parecido con la normalidad.
p-valor = 1.3631e-19	En esta variable, el p-valor es muy pequeño; por tanto, es razonable concluir que salary_in_usd no sigue una distribución normal.

7. ¿Qué significa una cola, un lado más cargado o una forma rara?

Cola a la derecha: Hay pocos valores muy altos que alargan la distribución. Esto suele ocurrir en salarios, ingresos, tiempos de espera o montos de compra.

Cola a la izquierda: Hay pocos valores muy bajos que estiran la distribución hacia la izquierda.

Más datos a un lado que al otro: La distribución está sesgada. La media y la mediana tienden a separarse y la interpretación basada solo en el promedio puede engañar.

Picos múltiples: Puede haber mezcla de subgrupos, por ejemplo cargos distintos, niveles de experiencia distintos o países diferentes dentro de la misma variable.

Muchos atípicos: La variable puede requerir revisión, filtrado contextual o transformaciones antes del modelado.

8. ¿Qué es multicolinealidad y por qué no es lo mismo que normalidad?

La normalidad analiza la forma de una sola variable. La multicolinealidad, en cambio, analiza la relación fuerte entre dos o más variables predictoras.

Existe multicolinealidad cuando varios predictores contienen información muy parecida entre sí. Esto puede dificultar la interpretación de algunos modelos, especialmente los lineales, porque el efecto de una variable se mezcla con el de otra.

La multicolinealidad no se detecta con histograma, QQ-plot o boxplot. Para revisarla se usan herramientas como matriz de correlación, VIF o análisis entre predictores.

9. ¿Cómo se debe analizar la normalidad de manera correcta?

1. Elegir primero una variable numérica con sentido analítico, por ejemplo salary_in_usd.
2. Mirar el histograma con curva normal para tener una impresión global de la forma.
3. Revisar el QQ-plot para comparar la variable con una normal teórica.
4. Confirmar con boxplot si hay asimetría o muchos valores atípicos.
5. Apoyarse en Shapiro-Wilk como evidencia estadística, sin olvidar el contexto del problema.
6. Concluir no solo si hay o no normalidad, sino qué patrón aparece: sesgo, colas, atípicos, mezcla de grupos o dispersión extrema.

10. Lectura aplicada al caso de salary_in_usd

El histograma muestra una distribución claramente sesgada hacia la derecha: la mayor parte de los salarios se concentra en rangos intermedios y aparecen salarios altos que alargan la cola.

El QQ-plot se aparta de la línea, sobre todo en los extremos, lo que indica que la variable no sigue bien una distribución normal.

El boxplot revela dispersión amplia y presencia de valores atípicos altos.

La prueba de Shapiro-Wilk refuerza esta lectura, pues el p-valor obtenido es extremadamente pequeño.

11. Recomendación pedagógica

Para tus estudiantes, una buena idea es enseñar esta secuencia: primero se observa la forma de la variable, luego se interpretan sesgos, colas y atípicos, y por último se decide si la variable requiere transformación o simplemente una lectura más cuidadosa. La normalidad no es una meta obligatoria; es una característica que se revisa para entender mejor los datos.

12. Código de referencia usado

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
from scipy.stats import norm, probplot, shapiro

df = pd.read_csv("ds_salaries_limpia.csv")
columna = "salary_in_usd"
datos = df[columna].dropna()

# Histograma + curva normal
plt.figure(figsize=(8,5))
plt.hist(datos, bins=20, density=True, edgecolor="black", alpha=0.7)
media = datos.mean()
desviacion = datos.std()
x = np.linspace(datos.min(), datos.max(), 200)
y = norm.pdf(x, media, desviacion)
plt.plot(x, y, linewidth=2, label="Campana de Gauss")
```

```
plt.legend()
plt.show()

# QQ-plot
plt.figure(figsize=(6,6))
probplot(datos, dist="norm", plot=plt)
plt.show()

# Boxplot
plt.figure(figsize=(8,2.5))
plt.boxplot(datos, vert=False)
plt.show()

# Shapiro-Wilk
muestra = datos.sample(min(5000, len(datos)), random_state=42)
estadistico, p_valor = shapiro(muestra)
print(estadistico, p_valor)
```