Librerias

Importar las librerias necesarias

In [77]:
```
import pandas as pd
import numpy as np
from sklearn.model_selection import train_test_split
from sklearn.linear_model import LinearRegression
from sklearn.tree import DecisionTreeRegressor, plot_tree
from sklearn.ensemble import RandomForestRegressor
from sklearn.metrics import mean_squared_error, r2_score, mean_absolute_error
import joblib
import matplotlib.pyplot as plt
```

Data

In [63]:
```
# abrir las datas
path=r"C:\Users\darly\Downloads"
data_con_outliner=pd.read_csv(path+r"\dataSalarios_final.csv")
data_sin_outliner=pd.read_csv(path+ r"\dataSalarios_final_outliner.csv")
```

In [64]:
```
data_con_outliner.shape, data_sin_outliner.shape
```

Out[64]:
```
((607, 107), (597, 107))
```

Valores de x, y para cada data, y sets de entranamiento y prueba

In [65]:
```
#data con atipicos
#Separar variables predictoras y objetivo
X1 = data_con_outliner.drop(columns=['salary_in_usd'])
y1 = data_con_outliner['salary_in_usd']

# Dividir en entrenamiento y prueba
X_train1, X_test1, y_train1, y_test1 = train_test_split(X1, y1, test_size=0.2, random_state=42)
```

In [66]:
```
#data sin atipicos
#Separar variables predictoras y objetivo
X2 = data_sin_outliner.drop(columns=['salary_in_usd'])
y2 = data_sin_outliner['salary_in_usd']

# Dividir en entrenamiento y prueba
X_train2, X_test2, y_train2, y_test2 = train_test_split(X2, y2, test_size=0.2, random_state=42)
```

Modelos

árboles de decisión

In [24]:
```
# Crear y entrenar el modelo con data con datos atipicos
modelo_arbol1 = DecisionTreeRegressor(random_state=42)
modelo_arbol1.fit(X_train1, y_train1)

# Predecir
y_pred_arbol1 = modelo_arbol1.predict(X_test1)

# Evaluar
r2_arbol1 = r2_score(y_test1, y_pred_arbol1)
mse_arbol1 = mean_absolute_error(y_test1, y_pred_arbol1)
rmse_arbol1 = np.sqrt(mean_squared_error(y_test1, y_pred_arbol1))

# Calcular la desviación estándar de y_test
std_y_test1= y_test1.std()

print("R²:", r2_arbol1)
print("MAE:", mse_arbol1)
print("RMSE:", rmse_arbol1)
print("STD:", std_y_test1)  #ser mas peque  RMSE
```

```
R²: 0.5074841776464774
MAE: 8818.975409836066
RMSE: 43446.52989284079
STD: 62163.038069299255
```

In [25]:
```
# Crear y entrenar el modelo con data sin datos atipicos
modelo_arbol2 = DecisionTreeRegressor(random_state=42)
```

```
modelo_arbol2.fit(X_train2, y_train2)

# Predecir
y_pred_arbol2 = modelo_arbol2.predict(X_test2)

# Evaluar
r2_arbol2 = r2_score(y_test2, y_pred_arbol2)
mse_arbol2 = mean_absolute_error(y_test2, y_pred_arbol2)
rmse_arbol2 = np.sqrt(mean_squared_error(y_test2, y_pred_arbol2))

# Calcular la desviación estándar de y_test
std_y_test2= y_test2.std()


print("R²:", r2_arbol2)
print("MAE:", mse_arbol2)
print("RMSE:", rmse_arbol2)
print("STD:", std_y_test2)  #ser mas peque RMSE
```

```
R²: 0.8761513299019494
MAE: 5077.25
RMSE: 18162.780554382818
STD: 51826.72957156338
```

In [26]:
```
#guardar los modelos
joblib.dump(modelo_arbol1, 'ARBOLES_conOutliner.pkl')
joblib.dump(modelo_arbol2, 'ARBOLES_SinOutliner.pkl')
```

Out[26]:
```
['ARBOLES_SinOutliner.pkl']
```

In [28]:
```
# Comparación de modelos
comparacion_modelos = pd.DataFrame({
    "Modelo": ["ARBOLES 1", "ARBOLES 2"],
    "RMSE": [rmse_arbol1, rmse_arbol2],
    "R²": [r2_arbol1, r2_arbol2]
})
comparacion_modelos
```

Out[28]:

	Modelo	RMSE	R^2
0	ARBOLES 1	43446.529893	0.507484
1	ARBOLES 2	18162.780554	0.876151

In [34]:
```
#pintar modelos
#mirar puntos

plt.figure(figsize=(10, 6))

# Graficar cada punto (valor real vs predicho)
plt.scatter(range(len(y_test1)), y_test1, color='blue', label="Valores Reales", alpha=0.3)
plt.scatter(range(len(y_pred_arbol1)), y_pred_arbol1, color='red', label="Valores Predichos", alpha=0.3)

# Configurar el gráfico
plt.xlabel("Índice de Observación", fontsize=12)
plt.ylabel("Valores de Y", fontsize=12)
plt.title("Comparación entre Valores Reales y Predicciones", fontsize=14)
plt.legend()
plt.grid(True, linestyle="--", alpha=0.5)

# Mostrar gráfico
plt.show()
```

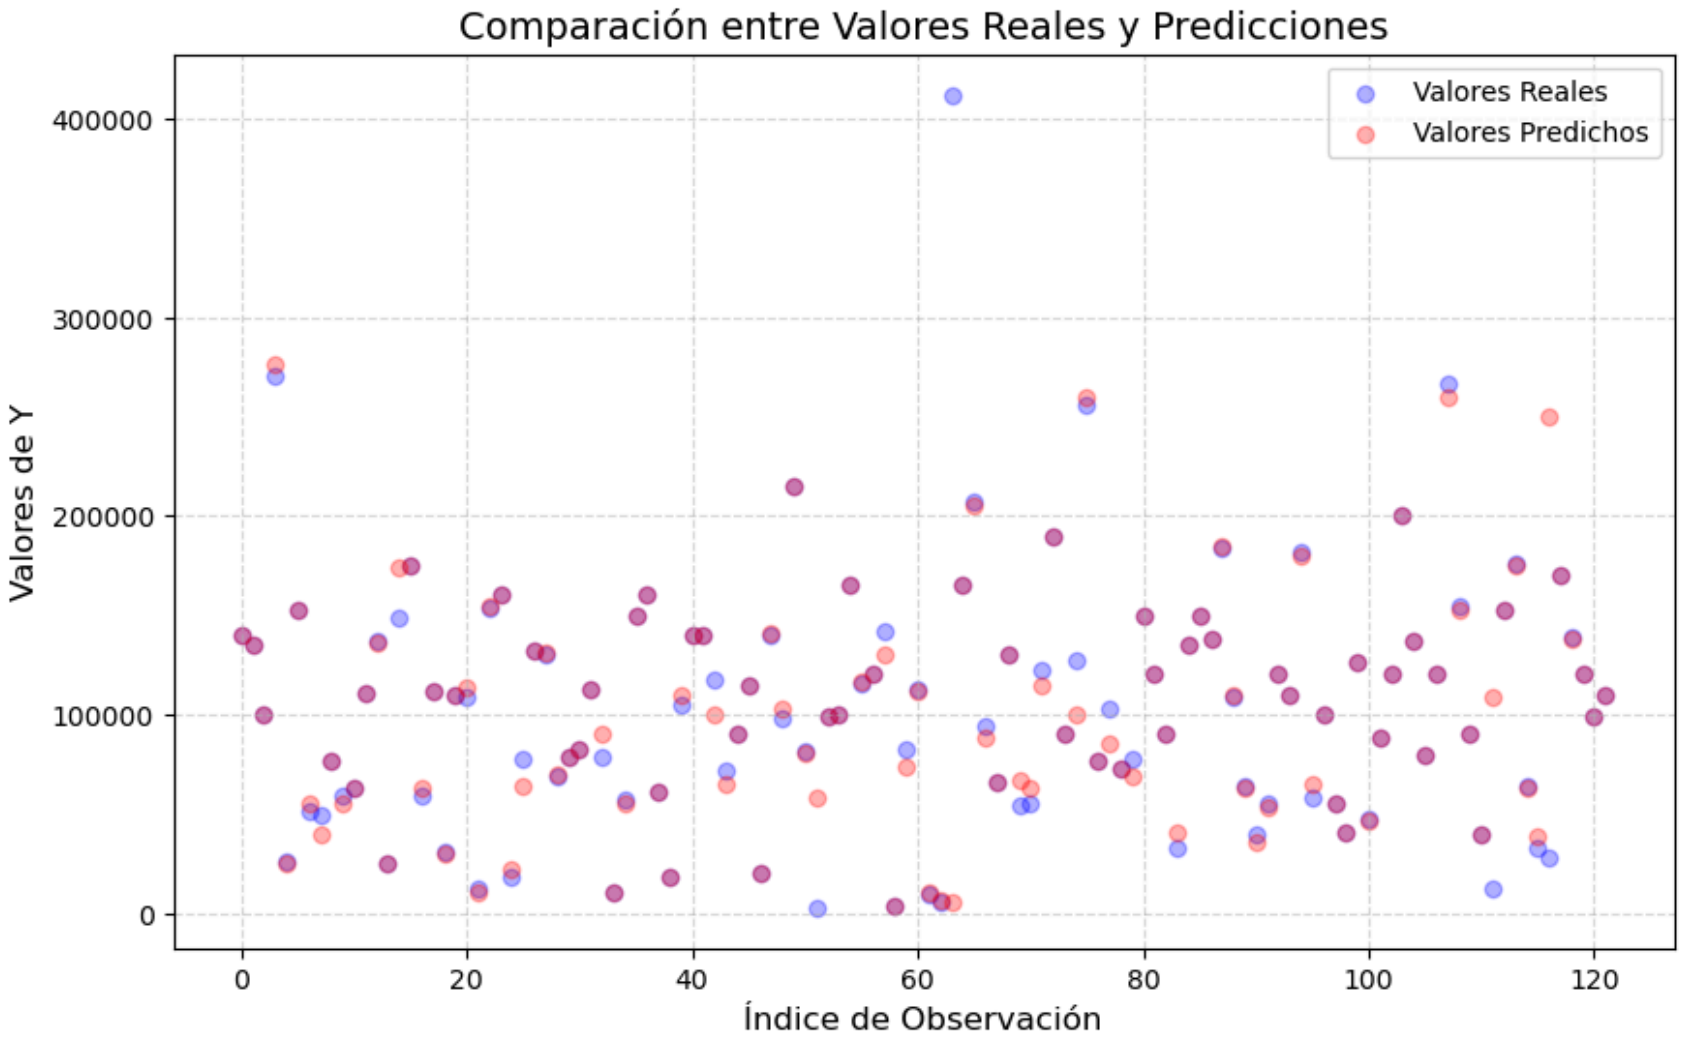

In [33]:
```
#pintar modelos
#mirar puntos

plt.figure(figsize=(10, 6))

# Graficar cada punto (valor real vs predicho)
plt.scatter(range(len(y_test2)), y_test2, color='blue', label="Valores Reales", alpha=0.3)
plt.scatter(range(len(y_pred_arbol2)), y_pred_arbol2, color='red', label="Valores Predichos", alpha=0.3)
```

```
# Configurar el gráfico
plt.xlabel("Índice de Observación", fontsize=12)
plt.ylabel("Valores de Y", fontsize=12)
plt.title("Comparación entre Valores Reales y Predicciones", fontsize=14)
plt.legend()
plt.grid(True, linestyle="--", alpha=0.5)

# Mostrar gráfico
plt.show()
```

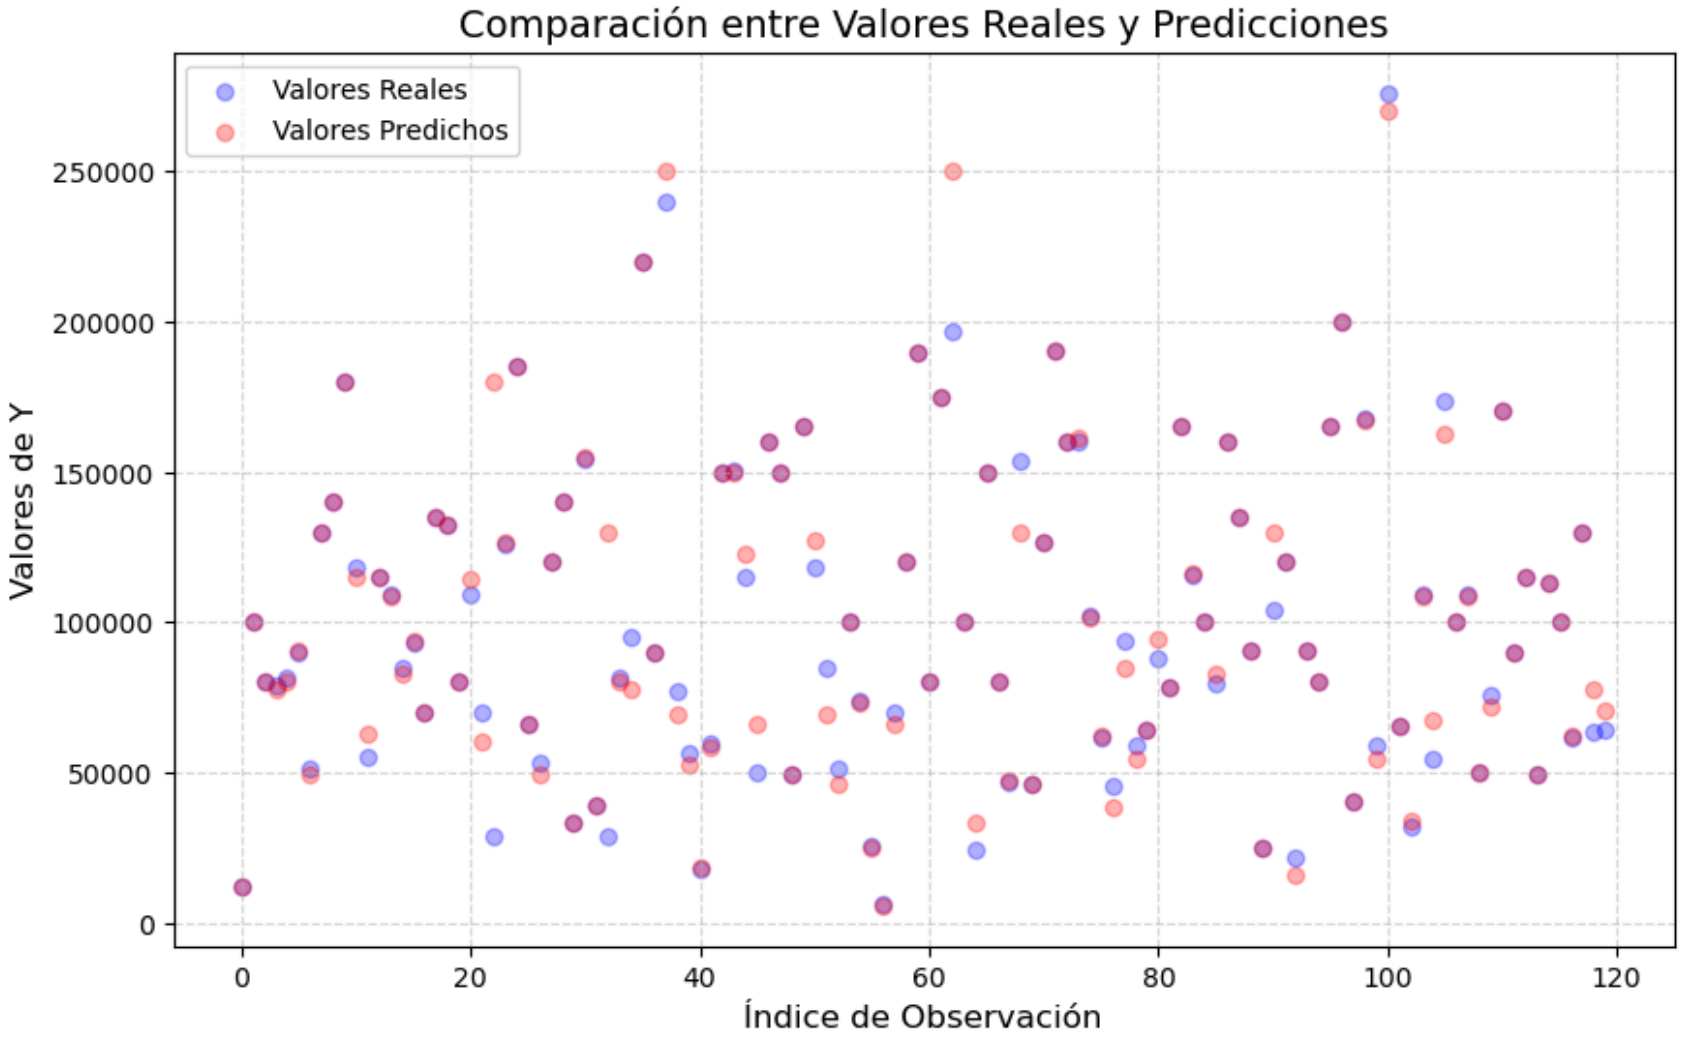

Analizar la profundidad del arbol

In [40]:
```
#mirar profundida en el arbol ---tener cuidado con el overfiting
modelo_arbol1.get_depth(), modelo_arbol2.get_depth()
```

Out[40]: (17, 16)

Revisar si no hay sobre entrenamiento u overfiting

Si R^2 de entrenamiento es muy alto (por ejemplo, 0.99) y el R^2 de prueba es muy bajo (por ejemplo, 0.6 o negativo), hay overfitting.

In [42]:
```
 # Predicciones en entrenamiento y prueba
y_pred_train = modelo_arbol1.predict(X_train1)
y_pred_test = modelo_arbol1.predict(X_test1)

# Métricas
r2_train = r2_score(y_train1, y_pred_train)
r2_test = r2_score(y_test1, y_pred_test)

print("R² Entrenamiento:", r2_train)
print("R² Prueba:", r2_test)
```

```
R² Entrenamiento: 1.0
R² Prueba: 0.5074841776464774
```

In [43]:
```
# Predicciones en entrenamiento y prueba
y_pred_train = modelo_arbol2.predict(X_train2)
y_pred_test = modelo_arbol2.predict(X_test2)

# Métricas
r2_train = r2_score(y_train2, y_pred_train)
r2_test = r2_score(y_test2, y_pred_test)

print("R² Entrenamiento:", r2_train)
print("R² Prueba:", r2_test)
```

```
R² Entrenamiento: 1.0
R² Prueba: 0.8761513299019494
```

Interpretación

El modelo de árbol de decisión muestra un desempeño perfecto en el conjunto de entrenamiento con un R^2 de 1.0, lo que indica que ha memorizado completamente esos datos. Sin embargo, en el conjunto de prueba obtiene un R^2 de 0.876, lo cual sigue siendo un valor alto y refleja una buena capacidad de generalización. Esta diferencia entre ambos resultados sugiere la presencia de un leve sobreajuste, típico de los árboles sin restricciones de profundidad. Aunque el modelo aún ofrece predicciones confiables, podría beneficiarse de ajustes como limitar la profundidad del árbol o aplicar validación cruzada para mejorar su robustez y evitar depender demasiado de los datos de entrenamiento.

vamos a probar con la data sin atipicos que parece comportarse mejor, varios niveles de profundidad en el árbol

In [69]:
```
for i in range(1,16):

    print("nivel " , i)
    print()
    modelo_arbol = DecisionTreeRegressor(max_depth=i, random_state=42)
    modelo_arbol.fit(X_train2, y_train2)

    # Predicciones en entrenamiento y prueba
    y_pred_train = modelo_arbol.predict(X_train2)
    y_pred_test = modelo_arbol.predict(X_test2)

    # Métricas9
    r2_train = r2_score(y_train2, y_pred_train)
    r2_test = r2_score(y_test2, y_pred_test)

    print("R² Entrenamiento en modelo con depth:", i , r2_train)
    print("R² Prueba en modelo con depth :", i,  r2_test)
    print("::::::::::::::::::::::::::::::::::::::::::::::::::")
```

```
nivel  1

R² Entrenamiento en modelo con depth: 1 0.39188603730034266
R² Prueba en modelo con depth : 1 0.3629602446992194
::::::::::::::::::::::::::::::::::::::::::::::::::
nivel  2

R² Entrenamiento en modelo con depth: 2 0.694851359452106
R² Prueba en modelo con depth : 2 0.6362895718573363
::::::::::::::::::::::::::::::::::::::::::::::::::
nivel  3

R² Entrenamiento en modelo con depth: 3 0.8542024976116501
R² Prueba en modelo con depth : 3 0.8187174967503166
::::::::::::::::::::::::::::::::::::::::::::::::::
nivel  4

R² Entrenamiento en modelo con depth: 4 0.904889047975608
R² Prueba en modelo con depth : 4 0.8629050948999153
::::::::::::::::::::::::::::::::::::::::::::::::::
nivel  5

R² Entrenamiento en modelo con depth: 5 0.9465122927123668
R² Prueba en modelo con depth : 5 0.8723289390165666
::::::::::::::::::::::::::::::::::::::::::::::::::
nivel  6

R² Entrenamiento en modelo con depth: 6 0.9723101502561459
R² Prueba en modelo con depth : 6 0.8774244143758395
::::::::::::::::::::::::::::::::::::::::::::::::::
nivel  7

R² Entrenamiento en modelo con depth: 7 0.9868474962004075
R² Prueba en modelo con depth : 7 0.8802471407364851
::::::::::::::::::::::::::::::::::::::::::::::::::
nivel  8

R² Entrenamiento en modelo con depth: 8 0.9928068129241194
R² Prueba en modelo con depth : 8 0.8793259317692329
::::::::::::::::::::::::::::::::::::::::::::::::::
nivel  9
```

```
R² Entrenamiento en modelo con depth: 9 0.997147188897369
R² Prueba en modelo con depth : 9 0.8832525807740219
::::::::::::::::::::::::::::::::::::::::::::::::::
nivel  10

R² Entrenamiento en modelo con depth: 10 0.9990754645733917
R² Prueba en modelo con depth : 10 0.8799209792747239
::::::::::::::::::::::::::::::::::::::::::::::::::
nivel  11

R² Entrenamiento en modelo con depth: 11 0.9997131784587208
R² Prueba en modelo con depth : 11 0.8759186147709367
::::::::::::::::::::::::::::::::::::::::::::::::::
nivel  12

R² Entrenamiento en modelo con depth: 12 0.99992893623965
R² Prueba en modelo con depth : 12 0.8763609986543718
::::::::::::::::::::::::::::::::::::::::::::::::::
nivel  13

R² Entrenamiento en modelo con depth: 13 0.9999814419680716
R² Prueba en modelo con depth : 13 0.8767369673411561
::::::::::::::::::::::::::::::::::::::::::::::::::
nivel  14

R² Entrenamiento en modelo con depth: 14 0.9999986872806125
R² Prueba en modelo con depth : 14 0.8815224873801514
::::::::::::::::::::::::::::::::::::::::::::::::::
nivel  15

R² Entrenamiento en modelo con depth: 15 0.9999998917749352
R² Prueba en modelo con depth : 15 0.8781517165310334
::::::::::::::::::::::::::::::::::::::::::::::::::
```

modelo elegido

- en el análisis parare comportarse mejor con depth 9

In [70]:
```
# Crear y entrenar el modelo con data con datos atipicos
#el mejor modelo fue depth en 93
```

```
modelo_arbol3 = DecisionTreeRegressor(max_depth=9, random_state=42)
modelo_arbol3.fit(X_train2, y_train2)

# Predecir
y_pred_arbol3 = modelo_arbol3.predict(X_test2)

# Evaluar
r2_arbol3 = r2_score(y_test2, y_pred_arbol3)
mse_arbol3 = mean_absolute_error(y_test2, y_pred_arbol3)
rmse_arbol3 = np.sqrt(mean_squared_error(y_test2, y_pred_arbol3))

# Calcular la desviación estándar de y_test
std_y_test3= y_test2.std()


print("R²:", r2_arbol3)
print("MAE:", mse_arbol3)
print("RMSE:", rmse_arbol3)
print("STD:", std_y_test3)  #ser mas peque RMSE
```

```
R²: 0.8832525807740219
MAE: 6034.369846524306
RMSE: 17634.384525312922
STD: 51826.72957156338
```

In [71]:

```
# Comparación de modelos
comparacion_modelos = pd.DataFrame({
    "Modelo": ["ARBOLES 1", "ARBOLES 2", "ARBOLES 3"],
    "RMSE": [rmse_arbol1, rmse_arbol2, rmse_arbol3],
    "R²": [r2_arbol1, r2_arbol2, r2_arbol3]
})
comparacion_modelos
```

Out[71]:

	Modelo	RMSE	R²
0	ARBOLES 1	43446.529893	0.507484
1	ARBOLES 2	18162.780554	0.876151
2	ARBOLES 3	17634.384525	0.883253

In [74]:
```
#guardar modelo
#guardar los modelos
joblib.dump(modelo_arbol3, r"C:\Users\darly\Downloads\ARBOLES_sinOutliner_dep9.pkl")
```

Out[74]:
```
['C:\\Users\\darly\\Downloads\\ARBOLES_sinOutliner_dep9.pkl']
```

In [75]:
```
#pintar modelos
#mirar puntos

plt.figure(figsize=(10, 6))

# Graficar cada punto (valor real vs predicho)
plt.scatter(range(len(y_test2)), y_test2, color='blue', label="Valores Reales", alpha=0.3)
plt.scatter(range(len(y_pred_arbol3)), y_pred_arbol3, color='red', label="Valores Predichos", alpha=0.3)

# Configurar el gráfico
plt.xlabel("Índice de Observación", fontsize=12)
plt.ylabel("Valores de Y", fontsize=12)
plt.title("Comparación entre Valores Reales y Predicciones", fontsize=14)
plt.legend()
plt.grid(True, linestyle="--", alpha=0.5)

# Mostrar gráfico
plt.show()
```

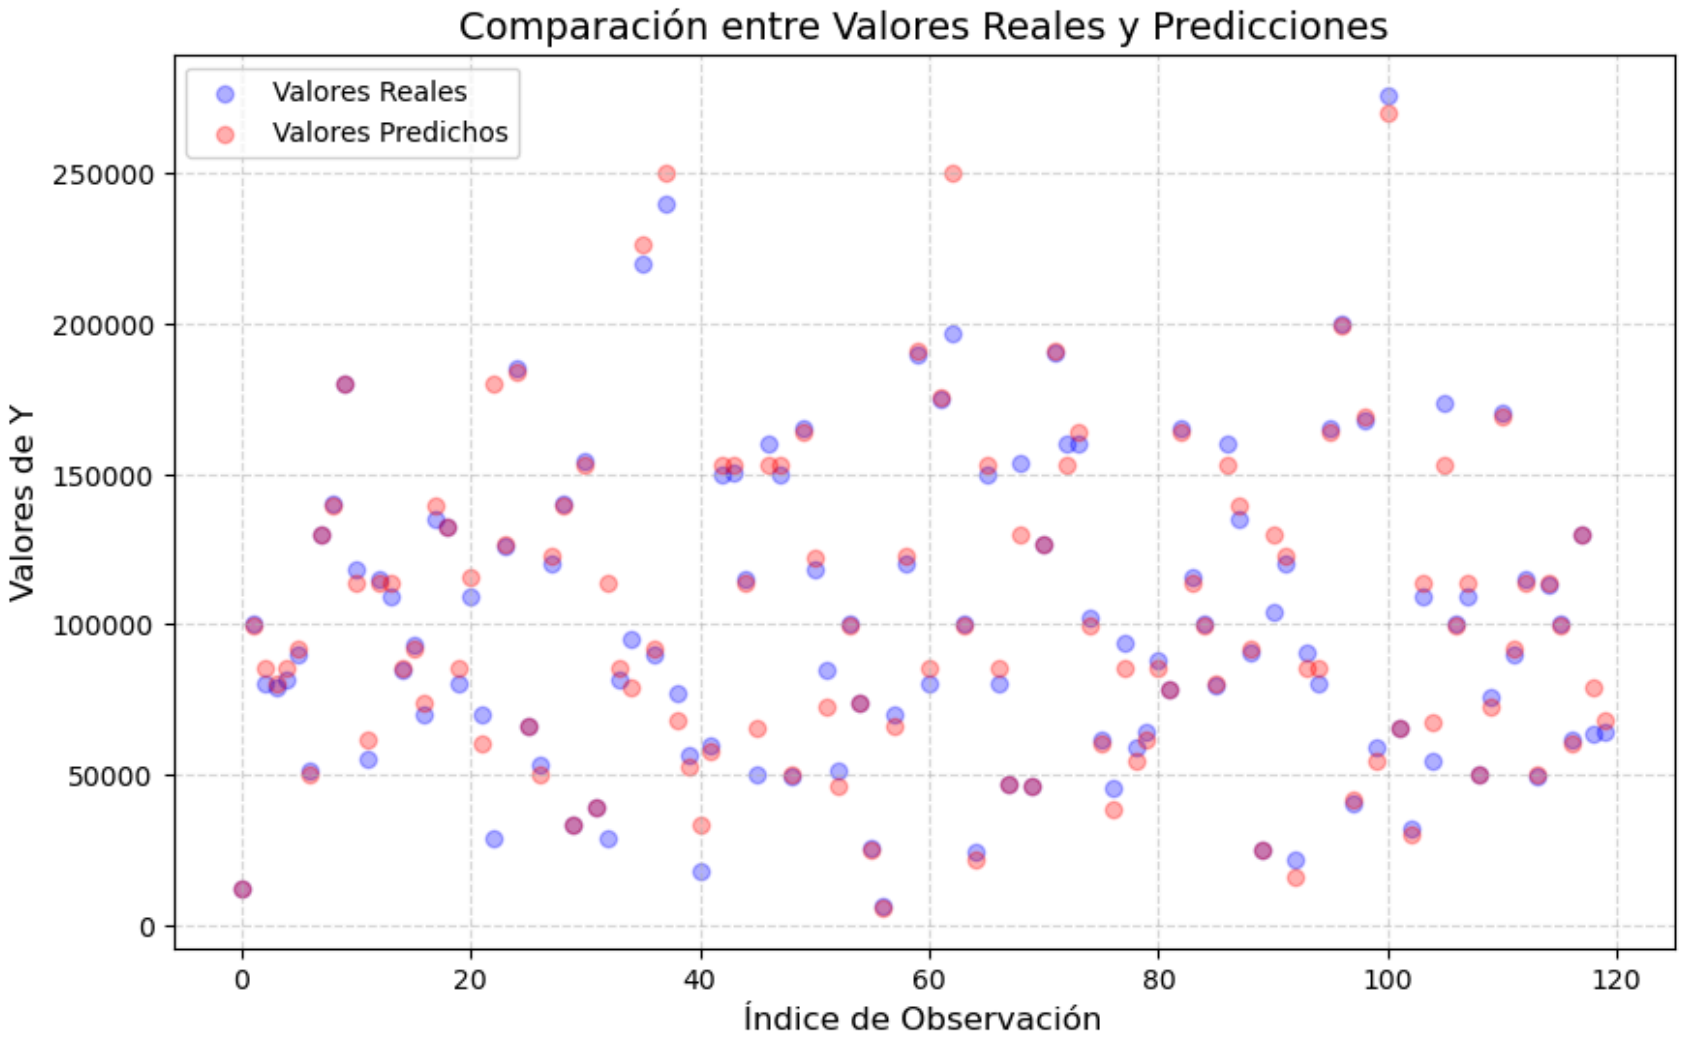

pintar arbol de decisiones

In [78]:
```
# Visualizar el árbol de decisión
plt.figure(figsize=(20, 10))  # Tamaño del gráfico
plot_tree(modelo_arbol3,
          filled=True,
          feature_names=X2.columns,
          fontsize=8)
```

```
plt.title("Árbol de Decisión (profundidad = 9)")
plt.show()
```

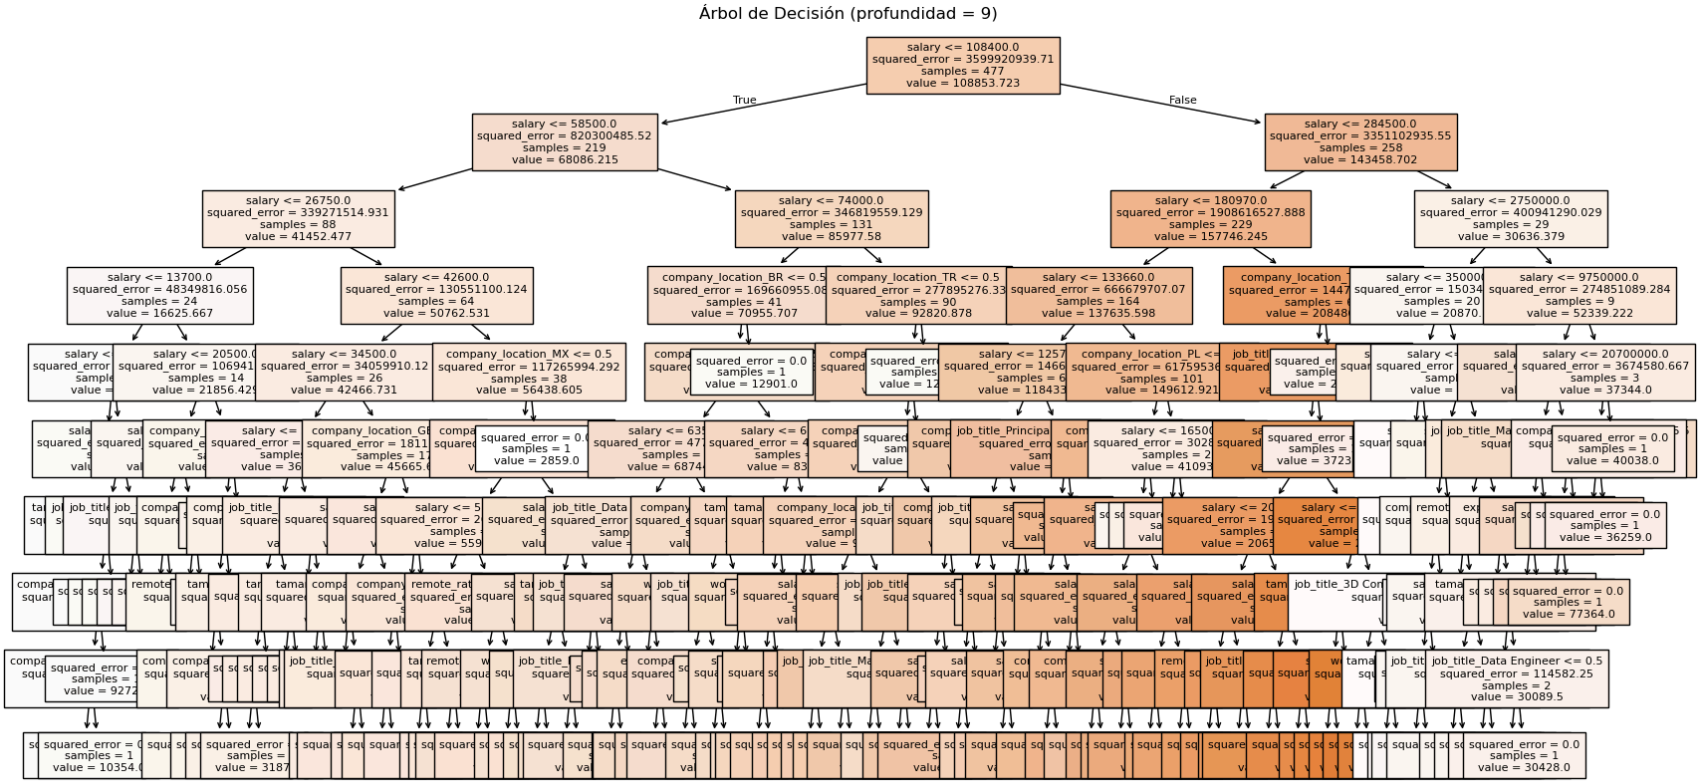

cargar modelos guardados

In [103…

```
path= r'C:\Users\darly\OneDrive\Escritorio\materialClaseIA\modelos'
# Datos de entrada
model_paths = {
    #'RL simple': path+r'\modelo_entrenado_columnaExperienciaSC.pkl',
    'RL múltiple con atipicos': path+r'\RMultiple_outliner.pkl',
    #'RL múltiple sin atipicos': path+r'\RMultiple_datTrasns.pkl',
    'RL múltiple con atipicos': path+r'\RMultiple_outliner.pkl',
  # 'Arboles sin atipicos': path+r'\ARBOLES_SinOutliner.pkl',
    'Arboles con atipicos': path+r'\ARBOLES_conOutliner.pkl',
    'Arboles con atipicos deph 9': path+r'\ARBOLES_sinOutliner_dep9.pkl',
   # 'Random sin atipicos': path+r'\RanForest_SinOutliner.pkl',
```

```
    'Random con atipicos': path+r'\RanForest_conOutliner.pkl'
}

# Crear una lista para guardar resultados
resultados = []

for nombre_modelo, ruta in model_paths.items():
    # Cargar el modelo
    modelo = joblib.load(ruta)

    # Predicciones
    y_train_pred = modelo.predict(X_train1)
    y_test_pred = modelo.predict(X_test1)

    # Métricas
    r2_train = r2_score(y_train1, y_train_pred)
    r2_test = r2_score(y_test1, y_test_pred)
    rmse_train = np.sqrt(mean_squared_error(y_train1, y_train_pred))
    rmse_test = np.sqrt(mean_squared_error(y_test1, y_test_pred))

    # Agregar resultados a la lista
    resultados.append({
        'Modelo': nombre_modelo,
        'R2 Entrenamiento': r2_train,
        'R2 Prueba': r2_test,
        'RMSE Entrenamiento': rmse_train,
        'RMSE Prueba': rmse_test
    })



# Convertir a DataFrame
df_resultados = pd.DataFrame(resultados)

#imprimir en forma de lista
print(resultados)
print("_____________________________________________________")
print()
# Mostrar tabla
print(df_resultados)

# Guardar resultados a CSV
```

```
path2= r'C:\Users\darly\OneDrive\Escritorio\materialClaseIA\dataSets\resultadosModelos'

df_resultados.to_csv(path2+r'\resultados_modelos_SINAtipicos.csv', index=False)
```

```
[{'Modelo': 'RL múltiple con atipicos', 'R2 Entrenamiento': 0.4990721980256533, 'R2 Prueba': 0.5889603008171753, 'RMS
E Entrenamiento': np.float64(51573.69037567944), 'RMSE Prueba': np.float64(39690.52886317273)}, {'Modelo': 'Arboles c
on atipicos', 'R2 Entrenamiento': 1.0, 'R2 Prueba': 0.5074841776464774, 'RMSE Entrenamiento': np.float64(0.0), 'RMSE
Prueba': np.float64(43446.52989284079)}, {'Modelo': 'Arboles con atipicos deph 9', 'R2 Entrenamiento': 0.386235580929
5339, 'R2 Prueba': 0.6432182798868681, 'RMSE Entrenamiento': np.float64(57087.56177931733), 'RMSE Prueba': np.float64
(36978.24527032591)}, {'Modelo': 'Random con atipicos', 'R2 Entrenamiento': 0.9563701133808505, 'R2 Prueba': 0.842219
1438905804, 'RMSE Entrenamiento': np.float64(15220.631892285259), 'RMSE Prueba': np.float64(24590.771557216103)}]
```

	Modelo	R2 Entrenamiento	R2 Prueba	\
0	RL múltiple con atipicos	0.499072	0.588960	
1	Arboles con atipicos	1.000000	0.507484	
2	Arboles con atipicos deph 9	0.386236	0.643218	
3	Random con atipicos	0.956370	0.842219	

	RMSE Entrenamiento	RMSE Prueba
0	51573.690376	39690.528863
1	0.000000	43446.529893
2	57087.561779	36978.245270
3	15220.631892	24590.771557

In [104…

```
path= r'C:\Users\darly\OneDrive\Escritorio\materialClaseIA\modelos'
# Datos de entrada
model_paths = {
    #'RL simple': path+r'\modelo_entrenado_columnaExperienciaSC.pkl',
    #'RL múltiple sin atipicos': path+r'\RMultiple_outliner.pkl',
    'RL múltiple sin atipicos': path+r'\RMultiple_datTrasns.pkl',
    #'RL múltiple sin atipicos': path+r'\RMultiple_outliner.pkl',
    'Arboles sin atipicos': path+r'\ARBOLES_SinOutliner.pkl',
    #'Arboles sin atipicos': path+r'\ARBOLES_conOutliner.pkl',
    'Arboles sin atipicos deph 9': path+r'\ARBOLES_sinOutliner_dep9.pkl',
    'Random sin atipicos': path+r'\RanForest_SinOutliner.pkl',
    #'Random sin atipicos': path+r'\RanForest_conOutliner.pkl'
}

# Crear una lista para guardar resultados
resultados = []
```

```python
for nombre_modelo, ruta in model_paths.items():
    # Cargar el modelo
    modelo = joblib.load(ruta)

    # Predicciones
    y_train_pred = modelo.predict(X_train2)
    y_test_pred = modelo.predict(X_test2)

    # Métricas
    r2_train = r2_score(y_train2, y_train_pred)
    r2_test = r2_score(y_test2, y_test_pred)
    rmse_train = np.sqrt(mean_squared_error(y_train2, y_train_pred))
    rmse_test = np.sqrt(mean_squared_error(y_test2, y_test_pred))

    # Agregar resultados a la lista
    resultados.append({
        'Modelo': nombre_modelo,
        'R2 Entrenamiento': r2_train,
        'R2 Prueba': r2_test,
        'RMSE Entrenamiento': rmse_train,
        'RMSE Prueba': rmse_test
    })

# Convertir a DataFrame
df_resultados = pd.DataFrame(resultados)

# Mostrar tabla
print(df_resultados)

# Guardar resultados a CSV
path2= r'C:\Users\darly\OneDrive\Escritorio\materialClaseIA\dataSets\resultadosModelos'
df_resultados.to_csv(path2+r'\resultados_modelos_COnAtipicos.csv', index=False)
```

	Modelo	R2 Entrenamiento	R2 Prueba	RMSE Entrenamiento	RMSE Prueba
0	RL múltiple sin atipicos	0.572853	0.569506	39213.465784	33862.587084
1	Arboles sin atipicos	1.000000	0.876151	0.000000	18162.780554
2	Arboles sin atipicos deph 9	0.997147	0.883253	3204.667600	17634.384525
3	Random sin atipicos	0.987218	0.910799	6783.327632	15414.185833

In [ ]: